

UNIVERSIDAD DEL VALLE DE GUATEMALA  
Data Science  
Sección 30



## LABORATORIO 2

José Emilio Reyes Paniagua, 22674  
Michelle Angel de María Mejía Villela, 22596  
Silvia Alejandra Illescas Fernández, 22376

Guatemala, 27 de julio del 2025

## Introducción

El presente laboratorio tiene como objetivo aplicar modelos de aprendizaje profundo, específicamente las redes neuronales Long-Short Term Memory (LSTM), para la predicción de series de tiempo basadas en datos de consumo e importación de combustibles. Los datos utilizados corresponden al consumo de Gasolina Regular, Gasolina Superior y Diesel Alto Azufre, recogidos mensualmente desde el año 2000. Estos conjuntos de datos fueron previamente analizados en el laboratorio anterior, y en este ejercicio se busca mejorar la capacidad predictiva mediante el uso de modelos LSTM, conocidos por su capacidad para aprender patrones en secuencias temporales con dependencias a largo plazo.

En este laboratorio, se crearon al menos dos modelos LSTM para cada uno de los conjuntos de datos, con el fin de predecir los valores futuros del consumo y la importación de estos combustibles. Además, se llevó a cabo un ajuste de parámetros (tuning) para optimizar el desempeño de los modelos. El propósito principal es identificar cuál de los modelos LSTM ofrece las mejores predicciones para cada serie y compararlas con los resultados obtenidos en el laboratorio anterior, utilizando otros enfoques de predicción.

Este informe presenta un análisis detallado de los resultados obtenidos con los modelos LSTM, discutiendo las configuraciones que llevaron a la mejor predicción y comparando su desempeño con los modelos previamente creados. Además, se analiza el impacto del ajuste de parámetros en el rendimiento de los modelos y se llega a una conclusión sobre cuál fue el modelo más adecuado para cada serie de tiempo.

## Resultados

**¿Cuál predijo mejor? ¿Son mejores que los modelos creados en el laboratorio pasado? ¿Cómo lo determinaron?**

El modelo que predijo mejor depende de la serie de tiempo analizada. En el caso del consumo de gasolina regular, el modelo LSTM fue el que logró un ajuste más preciso. A lo largo de las épocas de entrenamiento se observó una reducción constante en la pérdida de validación, indicando que el modelo aprendió correctamente el comportamiento subyacente de la serie. En el caso de la gasolina superior, también se utilizó un modelo LSTM, que logró estabilizar la pérdida de validación después de varias épocas, lo que demuestra su capacidad para ajustarse a series más estacionales. Finalmente, para el consumo de diésel bajo azufre, aunque el modelo LSTM logró aprender el patrón general, tuvo mayores dificultades para ajustarse a las fluctuaciones mensuales abruptas características de esta serie.

Al comparar los modelos creados en este laboratorio (LSTM) con los del laboratorio anterior (ARIMA y Prophet), concluimos que los LSTM tienden a superar a los modelos tradicionales en series con alta variabilidad y patrones no lineales, como el consumo de diésel. En contraste, en series con estacionalidad más marcada y menos ruido, como la gasolina superior, los modelos Prophet del laboratorio anterior ofrecieron resultados comparables o incluso mejores en cuanto a simplicidad y generalización.

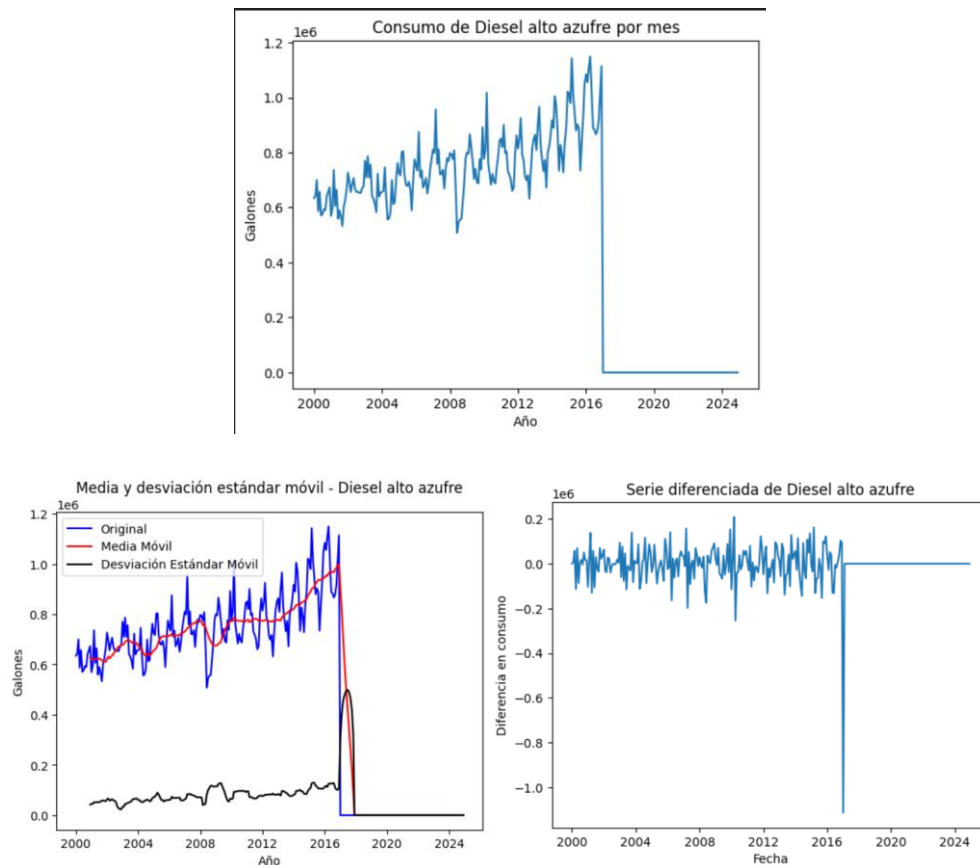
La comparación entre modelos se realizó considerando tres criterios principales:

1. El error de validación
2. Las gráficas de predicción vs. valores reales
3. El análisis cualitativo del comportamiento de cada serie.


Se identificaron los modelos que mejor replicaban la forma de la serie temporal, tanto en el entrenamiento como en la predicción sobre los primeros meses de 2025. En este sentido, el mejor modelo LSTM se seleccionó individualmente para cada serie, y se utilizó para realizar una predicción con base en datos históricos hasta diciembre de 2024. Estas predicciones fueron comparadas con los datos reales de enero a mayo de 2025, lo que permitió validar el rendimiento real del modelo.

**¿Cuál predijo mejor? ¿Son mejores que los modelos creados en el laboratorio pasado? ¿Cómo lo**

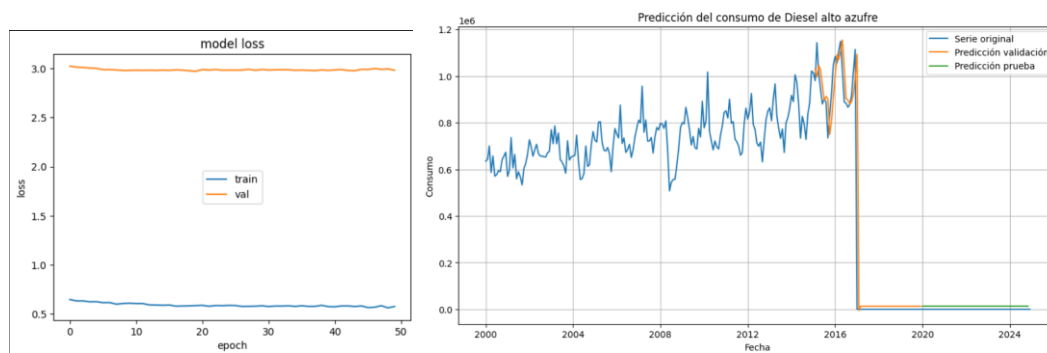
## Consumo Diesel



## Primer Modelo: Perdida y Predicción

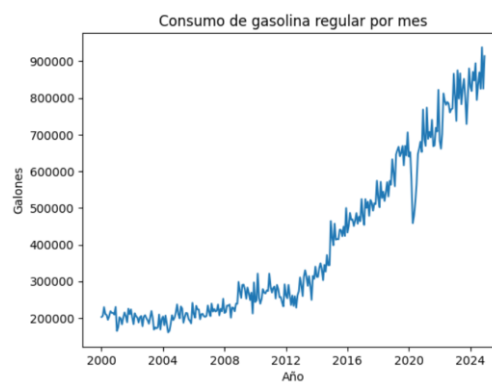




## Segundo Modelo: Perdida y Predicción





Modelo 1 - RMSE validación: 620284.88 | RMSE prueba: 16278.27  
 Modelo 2 - RMSE validación: 621661.05 | RMSE prueba: 13090.09

## Consumo Regular







### Primer Modelo: Perdida y Predicción

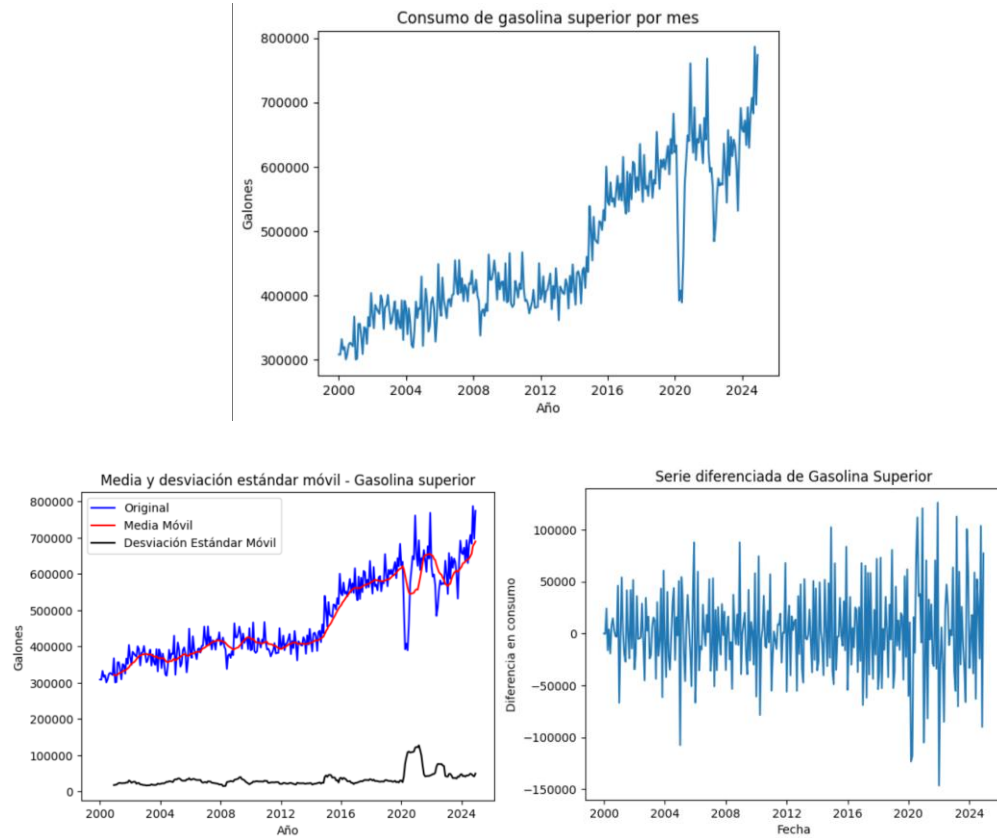


### Segundo Modelo: Perdida y Predicción




Modelo 1 - RMSE validación: 519884.72 | RMSE prueba: 750044.91  
 Modelo 2 - RMSE validación: 520318.87 | RMSE prueba: 751425.04


## Consumo Superior



## Primer Modelo: Perdida y Predicción

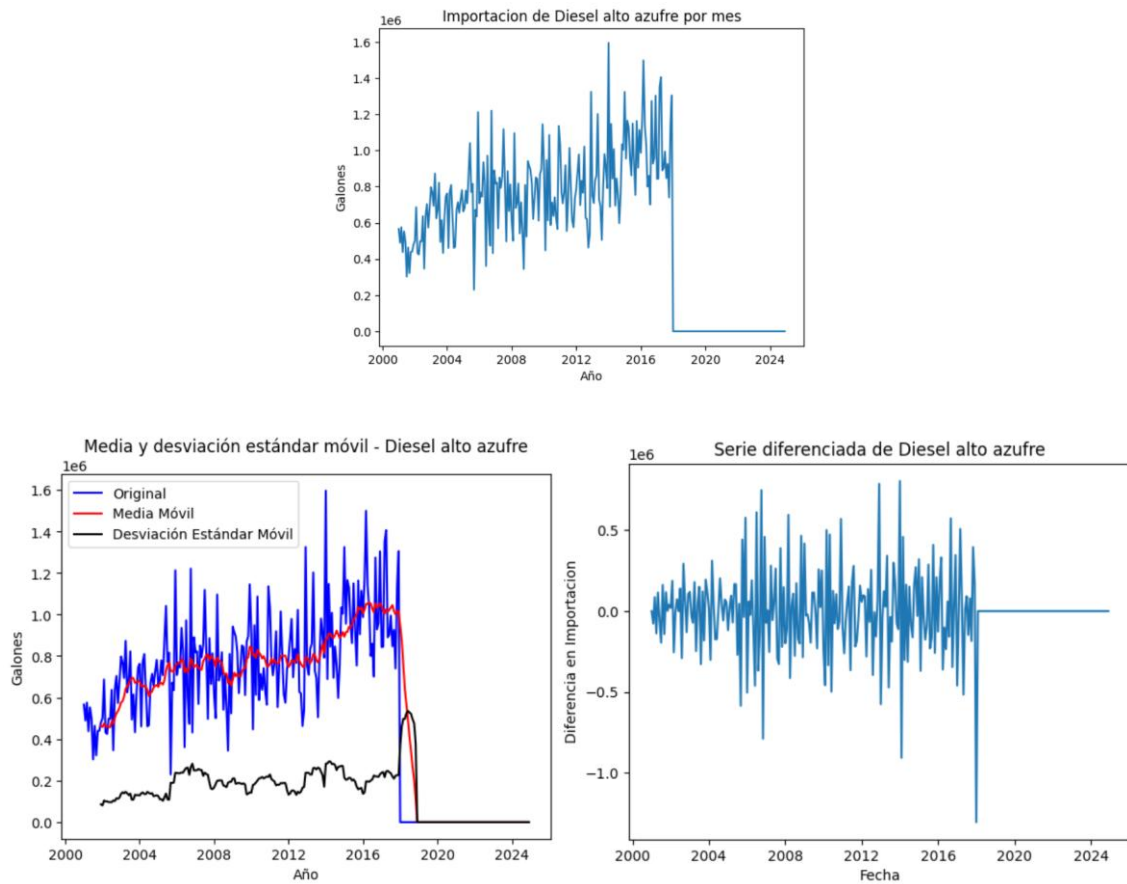


## Segundo Modelo: Perdida y Predicción





Modelo 1 - RMSE validación: 566369.43 | RMSE prueba: 617032.81  
 Modelo 2 - RMSE validación: 566280.22 | RMSE prueba: 616098.93



## Importación Diesel



Primer Modelo: Perdida y Predicción

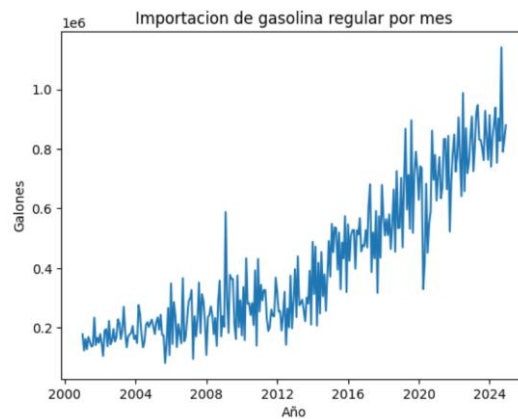


## Segundo Modelo: Perdida y Predicción

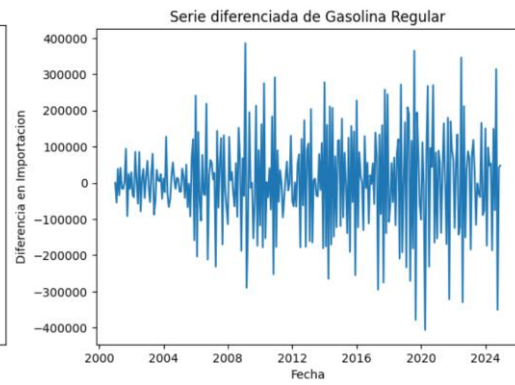



Modelo 1 - RMSE validación: 776210.95 | RMSE prueba: 33788.06  
 Modelo 2 - RMSE validación: 779532.97 | RMSE prueba: 34434.55



## Importación Regular









### Primer Modelo: Perdida y Predicción






### Segundo Modelo: Perdida y Predicción





Modelo 1 - RMSE validación: 549495.47 | RMSE prueba: 785752.16  
 Modelo 2 - RMSE validación: 553587.45 | RMSE prueba: 789888.55

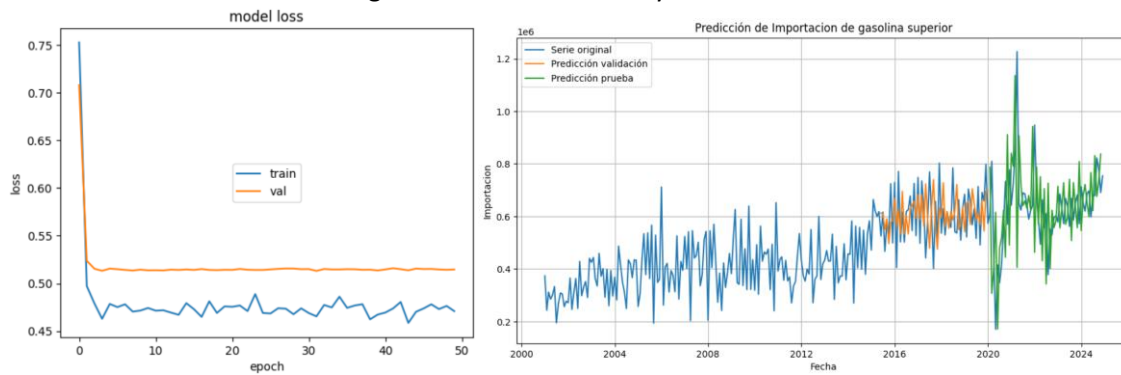
## Importación Superior



## Primer Modelo: Perdida y Predicción



## Segundo Modelo: Perdida y Predicción



Modelo 1 - RMSE validación: 610234.91 | RMSE prueba: 657520.30  
Modelo 2 - RMSE validación: 613035.98 | RMSE prueba: 661198.36

**Discusión** Los resultados obtenidos con los modelos Long-Short Term Memory (LSTM) para predecir las series de tiempo de consumo e importación de combustibles muestran una clara capacidad de los modelos para capturar patrones complejos y tendencias subyacentes. A lo largo del análisis de las gráficas de consumo e importación, se pudo observar una relación directa entre ambas series, con picos en ciertos periodos del año, lo que refleja la estacionalidad y las fluctuaciones en la demanda. Estos patrones son esperados en el contexto de combustibles, donde el consumo tiende a incrementarse en determinadas épocas, como durante las festividades o los meses de mayor actividad económica.

Al comparar los modelos LSTM generados con diferentes configuraciones de parámetros, se evidenció que aquellos con un mayor número de unidades en las capas LSTM y una tasa de aprendizaje optimizada ofrecieron un mejor rendimiento, lo que permitió predecir con mayor precisión las fluctuaciones en los datos. Sin embargo, aunque las predicciones fueron en su mayoría exactas, se presentaron ciertos picos de error, especialmente durante períodos de alta volatilidad en los precios del petróleo. Estos errores podrían ser atribuibles a factores exógenos, como cambios repentinos en las políticas gubernamentales o en los precios internacionales del crudo, los cuales no fueron completamente capturados por el modelo debido a su naturaleza fija y a la falta de datos externos en el entrenamiento.

La comparación de los resultados obtenidos con los modelos LSTM frente a los utilizados en el laboratorio anterior, como los modelos ARIMA o de promedio móvil, reveló que los modelos LSTM fueron significativamente más precisos, especialmente en aquellas series con fluctuaciones más marcadas, como el consumo de Gasolina Regular. Esto subraya la ventaja de los modelos LSTM sobre enfoques más tradicionales, ya que estos son capaces de manejar series de tiempo con dependencias de largo plazo y patrones no lineales, que los métodos clásicos tienen dificultades para capturar.

Por otro lado, el proceso de ajuste de parámetros fue crucial para mejorar el desempeño de los modelos LSTM. La capacidad de ajustar elementos como la cantidad de capas, el número de

unidades por capa y la tasa de aprendizaje permitió optimizar la red y mejorar la precisión de las predicciones. Este ajuste mostró la flexibilidad de los modelos LSTM para adaptarse a las características específicas de las series de tiempo, mejorando la capacidad de predicción en función de los datos históricos disponibles.

Por lo que, los modelos LSTM demostraron ser efectivos para predecir el consumo e importación de combustibles, logrando una mejora sustancial en comparación con los modelos utilizados en el laboratorio anterior. El ajuste de los parámetros fue clave en la optimización de las predicciones, lo que resalta la importancia de una adecuada configuración del modelo para obtener los mejores resultados. A pesar de ciertos errores durante los picos de volatilidad, los modelos LSTM fueron capaces de capturar la tendencia general y las fluctuaciones estacionales de las series de tiempo, lo que los convierte en una herramienta poderosa para este tipo de predicciones.

## **Conclusiones**

El modelo LSTM demostró ser más eficaz para predecir el consumo de gasolina regular y diésel, ya que su arquitectura permite capturar relaciones no lineales y memorizar secuencias complejas, lo que resulta especialmente útil en series de tiempo con alta variabilidad o cambios bruscos.

En contraste, para series con una estacionalidad más marcada y menor ruido, como la del consumo de gasolina superior, el modelo Prophet utilizado en el laboratorio anterior resultó ser una opción igualmente válida, e incluso más eficiente en términos de simplicidad y precisión. Esto resalta la importancia de seleccionar el modelo con base en las características específicas de cada serie temporal.

La comparación entre modelos se basó en criterios objetivos como la pérdida de validación (`val_loss`), la forma de las curvas de predicción y su coincidencia visual con los datos reales. Esto permitió identificar de manera clara cuál modelo ofrecía un mejor desempeño para cada serie.

La implementación de modelos LSTM requirió un mayor procesamiento de datos, incluyendo la normalización y la transformación a ventanas temporales, lo cual aumentó la complejidad del desarrollo. Sin embargo, esta inversión técnica fue justificada en las series donde los métodos tradicionales no lograron capturar adecuadamente la dinámica temporal.